

第 1 章 Introduction / 导论

基于 *A Course in Time Series Analysis* 的中文讲义与 Python 实践

本章学习目标

本章的作用是建立时间序列分析的入口视角。原文从最简单的独立随机变量出发，说明时间序列与经典统计的核心差别：观测值按照时间排序，并且相邻或相隔若干期的观测之间常常存在依赖结构。正是这种依赖结构，使预测、滤波、趋势识别和周期识别成为可能。

完成本章后，应能够：

- 说明什么是等间隔观测的时间序列；
- 区分无相关随机序列和具有时间结构的真实序列；
- 理解 SOI、Nasdaq、太阳黑子、气温等数据在时间序列课程中的典型用途；
- 将原文中的 R 入门绘图思路改写为 Python 实践；
- 理解线性滤波的基本表达式以及它在后续章节中的作用。

1 时间序列的基本概念

时间序列是一组按时间顺序记录的观测值，记作

$$x_t, \quad t \in \mathbb{Z}.$$

观测方式可以有多种：在一个连续区间上观测、在区间中随机抽样观测，或者在固定的等间隔时间点观测。本课程主要讨论第三种情形，即观测点之间间隔相同。为了便于数学表达，通常将时间下标写成整数集合

$$\mathbb{Z} = \{\dots, -1, 0, 1, 2, \dots\}.$$

最简单的时间序列是独立同分布随机变量序列。如果每个观测之间相互独立且均值为 0，那么从图形上通常看不到稳定的趋势、周期或可利用的依赖结构。此时，对下一期观测的最佳朴素预测往往只是均值 0。

时间序列分析真正关心的是观测之间的依赖。若当前值与过去值相关，过去信息就可能帮助我们预测未来；若序列中存在周期结构，我们可以识别周期；若均值随时间缓慢变化，我们需要估计趋势。




图 1: 独立无相关随机变量序列。该图对应原文 Figure 1.1 的教学意图: 序列围绕 0 上下波动, 但没有明显趋势或周期。

1.1 原文逐段补充

原文首先强调, 时间序列并不只是“一串数”, 而是一串在一段时间中观测到的数值。观测可以覆盖整个时间区间, 也可以是在某个区间内随机抽样获得, 还可以是在固定时间点上获得。不同的时间抽样方式会导致不同的数据分析方法。本课程选择最常见也最便于建立理论的设定: 观测发生在固定且等间隔的时间点上。因此, 后续都把观测写为

$$\{x_t : t \in \mathbb{Z}\},$$

其中

$$\mathbb{Z} = \{\dots, 0, 1, 2, \dots\}.$$

这一定义看似简单, 但它决定了后续所有滞后、差分、滤波、预测和频域分析的基本语言。

原文随后从最简单的时间序列例子开始: 独立且不相关的随机变量。它们当然也按时间排列, 因此形式上是时间序列; 但从图形上看, 这类序列没有清楚的模式。原文 Figure 1.1 展示的白色噪声序列围绕 0 上下波动, 既看不到趋势, 也看不到周期。若要求预测下一期观测, 最自然的预测值就是 0, 也就是图中看起来像均值的位置。

这一点用来说明时间序列与经典统计的关键差别。经典统计常从独立样本出发, 而时间序列最有价值的地方恰恰在于观测之间可能存在依赖。依赖意味着过去信息可能帮助预测未来, 也意味着不能简单套用独立样本的标准误、置信区间和显著性检验。原文要求读者记住 Figure 1.1 的白色噪声图, 并把它与随后四个真实数据例子比较: 真实时间序列通常会显示出某些模式。

2 典型时间序列数据

原文用四类数据说明时间序列问题的多样性。

2.1 南方涛动指数

南方涛动指数（Southern Oscillation Index, SOI）描述塔希提和达尔文之间海平面气压差的波动，是衡量厄尔尼诺现象强度的重要指标之一。原文使用 1876 年 1 月到 2014 年 7 月的月度 SOI 数据，并强调一个主要目标：寻找数据中的模式，特别是周期性。

在没有直接附带原始 SOI 数据文件的情况下，本章 Python 脚本生成一个具有周期成分和持续性噪声的模拟 SOI 序列，用于复现“月度气候指标具有波动结构”的教学场景。

原文指出，SOI 是衡量厄尔尼诺效应强度的指标。它记录塔希提与达尔文之间地表气压差的波动。Figure 1.2 给出 1876 年 1 月到 2014 年 7 月的月度 SOI 图形，并特别提醒：1930 年以前的数据可靠性存在一定疑问。原数据来自澳大利亚气象局网页。对于这类气候指数，本课程关注的主要问题不是单个观测值的大小，而是序列中是否存在可重复的模式，尤其是周期性。




图 2: 模拟的月度 SOI 型序列。图中可见慢周期波动和持续性噪声，这类结构适合引出周期检测和噪声问题。

2.2 Nasdaq 金融数据

原文展示了 1985 年 10 月 1 日至 2014 年 8 月 8 日的 Nasdaq 日收盘价。金融时间序列的直接动机常常是预测收益、风险或波动率。对于价格序列本身，常见现象包括长期增长、非平稳性和波动聚集；后续章节会逐步讨论差分、ARMA、ARCH/GARCH 等工具。

原文 Figure 1.3 使用的是 Nasdaq 日收盘价，时间范围为 1985 年 10 月 1 日到 2014 年 8 月 8 日。数据来源包括 Yahoo Finance 的历史数据，也提到美国联邦储备相关数据页面。原文用半开玩笑的方式说，对于这类金融数据，目标当然是“赚钱”；从统计角度说，核心任务是预测未来，特别是预测未来波动率。金融价格序列常表现为非平稳水平、长期变化和阶段性剧烈波动，因此后续需要研究收益率、差分、条件方差和非线性模型。

2.3 太阳黑子数据

太阳黑子数量是经典时间序列案例。太阳活动具有明显的周期性，因此适合用来引出周期识别、谱分析和长期预测。下面的 Python 图使用 statsmodels 内置太阳黑子数据。

太阳黑子活动由太阳表面可见黑子数量衡量。原文说明, 近些年太阳黑子重新受到关注, 是因为高太阳活动时期可能严重干扰通信网络。Figure 1.4 给出 1700 年到 2013 年年度太阳黑子数, 数据来自 SILSO 数据页面。此类数据的目标有两个: 一是寻找序列中的模式, 二是预测未来太阳黑子活动。由于太阳黑子序列具有明显的周期波动, 它是本课程引入周期检测和谱分析的经典案例。




图 3: 年度太阳黑子数量。可观察到明显的周期波动, 是后续研究周期和谱密度的典型案例。

2.4 年度与月度气温数据

气温异常序列常用于研究长期均值变化。原文指出, 若目标是检测全球变暖, 就不能只画一条趋势线后直接下结论, 还需要时间序列统计推断来判断趋势估计是否显著。原因在于, 时间序列观测通常不是独立样本, 相关性会改变估计量的标准误和显著性判断。

原文考虑两类全球温度数据: 1880 年到 2013 年的年度温度异常, 以及 1996 年 1 月到 2014 年 7 月的月度平均温度。Figure 1.5 展示年度温度异常, Figure 1.6 展示月度温度。数据来源为 NASA GISS 提供的全球温度数据文件。研究这类数据时, 一个自然问题是检测全球变暖, 即检测平均温度是否存在长期变化或上升。通常做法是对数据拟合趋势函数, 但原文强调, 仅仅拟合趋势线并不足够; 必须使用更细致的时间序列分析, 判断趋势估计是否具有统计显著性。原因在于温度序列存在相关性和季节结构, 不能把每个观测简单当作独立样本。

3 从 R 代码到 Python 实践

原文提醒读者熟悉 R, 并给出了 `ts()` 和 `plot.ts()` 的基本用法。在 Python 中, 类似工作通常由 `pandas` 的时间索引、`matplotlib` 绘图和 `statsmodels` 建模共同完成。

Listing 1: Python 中构造月度时间序列的基本模式

```
import pandas as pd

dates = pd.date_range("1876-01-01", periods=120, freq="MS")
```

```
series = pd.Series(range(120), index=dates)
series.plot()
```

原文第 1.2 节说明，课程中的很多方法和概念会用 R 语言展示，因此不熟悉 R 的读者应先掌握基础语法。原文给出了读取数据和构造时间序列对象的示例：假设 SOI 数据保存在主目录中，可以用 `scan()` 读入；随后用 `ts()` 创建时间序列对象。例如，月度数据从 1876 年 1 月开始，频率设置为 12，因为一年有 12 个观测。用 `plot.ts()` 可以直接画出时间序列图。

R 代码中的 `start=c(1876,1)` 表示起始年份为 1876 年、起始月份为 1 月；`frequency=12` 表示每年 12 个观测。原文还特别指出，正确地给图形标注日期非常有用。R 中可以借助 `zoo` 包和 `as.Date()` 函数处理日期。在 Python 中，与之对应的做法是使用 `pandas.date_range()` 创建时间索引，用 `Series` 或 `DataFrame` 保存观测，再用 `matplotlib` 或 `pandas` 内置绘图函数作图。

原文 R 代码逐行含义如下。第一行

```
soi <- scan("~/soi.txt")
```

表示从文本文件读入 SOI 数据。第二行用 `ts()` 把数值向量转换为带时间属性的对象，其中起点是 1876 年 1 月，频率是 12。原文代码片段中变量名写成 `monthlytemp`，结合上下文应理解为要传入已经读入的月度序列。随后 `plot.ts(soi1)` 直接绘图。若要在 Python 中保持同样信息，关键是不要只保存裸数组，而要同时保存日期索引；否则图形横轴无法正确显示年份和月份。

本章原文的六幅图也各有用途。Figure 1.1 是独立不相关随机变量，用作“没有模式”的基准图。Figure 1.2 是月度 SOI，用于展示气候指标中的周期和低频波动。Figure 1.3 是 Nasdaq 日收盘价，用于提示金融价格序列的非平稳性和预测动机。Figure 1.4 是太阳黑子年度数据，用于展示明显周期。Figure 1.5 是年度全球温度异常，用于引出长期趋势检测。Figure 1.6 是月度温度序列，用于说明高频季节变化和长期变化可能同时出现。把这些图放在同一章，是为了让读者从一开始就看到时间序列问题的多样性。

本章的完整实践脚本位于：

```
scripts/ch01_generate_figures.py.
```

运行后会在 `figures/` 目录生成本章所有图像。

4 时间序列滤波

为了突出某些特征或去除不需要的特征，我们经常对原始时间序列做变换。原文特别强调线性变换。设原始序列为 $\{X_t\}$ ，变换后的序列为 $\{Y_t\}$ ，则线性滤波可以写作

$$Y_t = \sum_{j=-\infty}^{\infty} h_j X_{t-j},$$

其中 $\{h_j\}$ 是一组权重。

本课程后续主要使用两类线性变换：

- 用于估计随时间变化的均值函数，例如移动平均平滑；
- 用于理解观测序列中的随机部分，例如频域变换和滤波。

原文第 1.3 节把这种操作称为 *filtering time series*。很多时候，我们会变换数据以突出想看的特征，或移除不想要的特征。常见变换包括对数变换和线性变换。对时间序列来说也是如此：变换后的序列可能比原序列更容易分析，或者显示出原图中不明显的特征。本讲义主要关注线性变换，因为它们既容易分析，又能直接连接到移动平均、差分、滤波和 Fourier 方法。

在线性滤波公式

$$Y_t = \sum_{j=-\infty}^{\infty} h_j X_{t-j}$$

中，权重 h_j 决定滤波器的作用。若权重集中在当前和附近时间点并且总和为 1，滤波器通常起到平滑作用；若权重之和为 0，例如一阶差分 $Y_t = X_t - X_{t-1}$ ，滤波器则会削弱低频趋势。原文在本章末尾预告，下一章将研究时间变化均值的估计，并会使用这里提到的变换。




图 4: 移动平均滤波示例。灰色曲线是带噪声观测，红色曲线是 13 点移动平均，展示了线性滤波如何突出低频趋势。

5 术语

iid independent and identically distributed，独立同分布。它是最简单的时间序列模型，但通常不是实际时间序列分析的终点。

预测 利用过去和当前信息推断未来观测。

趋势 序列均值随时间发生的系统性变化。

周期 序列中以某种频率重复出现的结构。

滤波 通过加权组合过去、当前或未来观测来变换序列。

原文第 1.4 节只列出了一个术语：iid，即 independent, identically distributed，独立同分布随机变量。原文称它是“你可能处理的最简单时间序列”。这句话的意思是：iid 序列虽然也按时间排列，但时间下标没有带来额外信息；任意一期与其他期独立，且分布相同。因此，它是时间序列理论的基准模型。后续所有复杂模型都可以与 iid 白噪声比较：如果残差已经接近 iid，说明模型较好地解释了序列中的可预测结构；如果残差仍有趋势、周期或相关性，说明模型还不充分。

因此，第 1 章完整内容可以概括为一条主线：先定义等间隔时间序列，再用白噪声说明“无结构”情形，然后用四类真实数据说明趋势、周期、波动和预测问题，接着给出 R 中创建和绘制时间序列对象的基本方法，最后引入线性滤波作为后续章节的共同工具。这里没有复杂定理，但每个概念都会在后面反复出现：第 2 章处理趋势，第 3 章处理平稳性，第 4 章处理线性模型，第 7 章处理预测，第 10 和第 11 章处理频域结构，第 13 章处理金融波动。

6 Python 工程实践

在本章目录下运行：

```
python scripts/ch01_generate_figures.py
```

脚本生成四张图：

- ch01_fig01_white_noise.png：独立无相关随机序列；
- ch01_fig02_simulated_soi.png：模拟 SOI 型月度序列；
- ch01_fig03_sunspots.png：太阳黑子年度序列；
- ch01_fig04_filtering.png：移动平均滤波。

7 练习提要

原文第 1 章的练习性质主要体现在读图、数据导入和基本滤波操作中。学习时可围绕下列方向展开：

- 用 Python 构造等间隔时间索引，并绘制白噪声、周期序列和带趋势序列；
- 比较 SOI、Nasdaq、太阳黑子和温度数据中趋势、周期和相关性的差异；
- 对同一序列尝试不同移动平均窗口，观察滤波后低频趋势和高频波动如何变化；
- 把原文中的 `ts()`、`plot.ts()` 思路改写为 `pandas.Series` 和 `matplotlib` 工作流。

本章小结

第 1 章的重点不是推导复杂模型，而是建立问题意识：时间序列数据的顺序和依赖结构很重要。独立随机变量序列几乎没有可预测结构，而气候、金融、太阳活动和温度序列往往具有

趋势、周期、波动聚集或相关噪声。后续章节会围绕这些结构展开：先研究趋势，再研究平稳性、线性模型、预测、估计、谱分析和非线性模型。