

第 2 章 Trends in a time series / 时间序列中的趋势

基于 *A Course in Time Series Analysis* 的中文讲义与 Python 实践

本章学习目标

本章研究时间序列中的均值函数或趋势项。原文把一个典型时间序列写成

$$Y_t = \mu_t + \varepsilon_t,$$

其中 $\mu_t = E(Y_t)$ 是不能由随机误差解释的系统性部分, ε_t 是残差或误差项。时间序列分析中常见的两类任务是: 估计 μ_t , 或者对 $\{Y_t\}$ 做变换, 使趋势项在变换后尽量消失, 从而集中研究残差的依赖结构。

完成本章后, 应能够:

- 使用参数模型描述线性、多项式、非线性和季节趋势;
- 用最小二乘和非线性最小二乘估计趋势参数;
- 理解差分如何移除确定性趋势和随机趋势, 以及过度差分的风险;
- 说明滚动窗口、筛估计等非参数趋势估计思想;
- 掌握离散傅里叶变换、周期图和周期检测的基本公式;
- 将原文中的 R 实践改写为 Python 图形与计算流程。

1 参数趋势

在许多时间序列问题中, 除了观测值 Y_t 外, 还可以使用解释变量。解释变量可以是外生变量, 也可以是时间 t 本身或时间的函数, 因为时间下标具有明确顺序。所谓参数模型, 是指除有限个未知参数外, 其余结构都已知的模型。

最简单的参数趋势是线性模型。原文给出的两个常用形式为

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t, \quad (2.1)$$

$$Y_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \varepsilon_t. \quad (2.2)$$

这些模型称为线性模型, 是因为它们对未知参数 $\beta_0, \beta_1, \beta_2$ 是线性的, 而不是因为趋势曲线一定是直线。

参数也可以出现在非线性函数内部。例如平滑转移模型可写为

$$Y_t = \frac{1}{1 + \exp\{\beta_0(t - \beta_1)\}} + \varepsilon_t, \quad (2.3)$$

其中 β_0 控制转移陡峭程度, β_1 控制转移位置。原文的 Figure 2.1 展示了在 $\sigma = 0.3$ 的独立噪声下, 不同 β_0 对转移形状的影响。

另一个非线性例子是用于刻画 ECG 数据的 burst signal 模型:

$$Y_t = A \exp\{\beta_0(1 - \cos(\beta_1 t))\} \cos(\theta t) + \varepsilon_t. \quad (2.4)$$

这类例子可统一写成

$$Y_t = g(x_t, \theta) + \varepsilon_t, \quad (2.5)$$

其中 g 是已知函数, θ 是未知参数。大多数趋势模型都会加入加性噪声项 $\{\varepsilon_t\}$, 用来表示趋势无法解释的变化。

季节行为常用正弦和余弦项描述。若周期长度为 P , 则可写成

$$Y_t = \beta_0 + \beta_1 \sin\left(\frac{2\pi t}{P}\right) + \beta_3 \cos\left(\frac{2\pi t}{P}\right) + \varepsilon_t.$$

当 P 已知时, 例如月度数据取 $P = 12$, 该模型是线性回归:

$$Y_t = \beta_0 + \beta_1 \sin\left(\frac{2\pi t}{12}\right) + \beta_3 \cos\left(\frac{2\pi t}{12}\right) + \varepsilon_t. \quad (2.6)$$

如果 P 也需要由数据估计, 则参数进入三角函数内部, 问题变为非线性模型。

1.1 最小二乘估计

先回顾单解释变量最小二乘。设 X_i 被认为会影响响应变量 Y_i , 将

$$Y_n = (Y_1, \dots, Y_n)'$$

投影到

$$X_n = (X_1, \dots, X_n)'$$

上, 最小二乘估计量定义为

$$\hat{\alpha}_n = \arg \min_{\alpha} \sum_{i=1}^n (Y_i - \alpha X_i)^2.$$

它有解析解

$$\hat{\alpha}_n = \frac{\langle Y_n, X_n \rangle}{\|X_n\|_2^2} = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2}.$$

几何上, 这是把 Y_n 投影到 X_n 张成的一维空间, 并得到

$$Y_n = \hat{\alpha}_n X_n + \varepsilon_n, \quad \langle X_n, \varepsilon_n \rangle = \sum_{i=1}^n X_i \varepsilon_{i,n} = 0.$$

到这里为止还只是几何投影。只有假设真实数据生成过程为

$$Y_i = \alpha X_i + \varepsilon_i,$$

并假设 X_i 与 ε_i 不相关, $\hat{\alpha}_n$ 才成为总体参数 α 的估计量。

多元线性回归把 Y_n 投影到多个解释变量 $(X_{1,n}, \dots, X_{p,n})$ 张成的空间。若 X 是设计矩阵，则

$$\hat{\alpha}_n = \arg \min_{\alpha} \sum_{i=1}^n \left(Y_i - \sum_{j=1}^p \alpha_j X_{i,j} \right)^2 = (X'X)^{-1} X'Y.$$

若各解释变量彼此正交，则 $X'X$ 为对角矩阵，第 j 个系数可简化为

$$\hat{\alpha}_{j,n} = \frac{\langle Y_n, X_{j,n} \rangle}{\|X_{j,n}\|_2^2} = \frac{\sum_{i=1}^n Y_i X_{i,j}}{\sum_{i=1}^n X_{i,j}^2}.$$

正交性有两点好处：一是估计公式简单，二是可避免解释变量之间的共线性问题。

对非线性模型 $Y_i = g(X_i, \theta) + \varepsilon_i$ ，仍可使用最小二乘：

$$\hat{\theta}_n = \arg \min_{\theta \in \Theta} \sum_{i=1}^n \{Y_i - g(X_i, \theta)\}^2.$$

通常 $\hat{\theta}_n$ 没有解析解，需要用数值优化求解。非线性优化对初始值敏感，尤其在参数较多时可能只找到局部最小值。

2 差分

差分是移除趋势的基本工具。以 Nasdaq 价格这类具有上升趋势的序列为例，若

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t,$$

则一阶差分

$$Z_t = Y_{t+1} - Y_t = \beta_1 + \varepsilon_{t+1} - \varepsilon_t$$

会消去截距和时间线性项，只留下常数项与误差差分。

一阶差分也适用于随机趋势。最简单的随机趋势模型为

$$Y_t = Y_{t-1} + \varepsilon_t, \tag{2.7}$$

其中 $\{\varepsilon_t\}$ 独立同分布。此时

$$Z_t = Y_{t+1} - Y_t = \varepsilon_{t+1}.$$

因此，差分把随机游走还原为创新序列。

更高阶差分可以移除更高阶多项式趋势。若

$$Y_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \varepsilon_t,$$

则

$$Z_t^{(1)} = Y_{t+1} - Y_t = \beta_1 + 2\beta_2 t + \varepsilon_{t+1} - \varepsilon_t,$$

仍含线性趋势；继续做二阶差分：

$$Z_t^{(2)} = Z_t^{(1)} - Z_{t-1}^{(1)} = 2\beta_2 + \varepsilon_{t+1} - 2\varepsilon_t + \varepsilon_{t-1}.$$

一般而言，多项式趋势的阶数决定需要差分的次数。类似地，若随机趋势为

$$Y_t = 2Y_{t-1} - Y_{t-2} + \varepsilon_t,$$

则二阶差分可回到创新项。

警告：不要过度差分。 过多差分会人为引入不自然的依赖。例如在线性趋势模型中，如果原误差 ε_t 独立，则

$$Z_t = Y_t - Y_{t-1} = \beta_1 + \varepsilon_t - \varepsilon_{t-1}$$

与

$$Z_{t+1} = \beta_1 + \varepsilon_{t+1} - \varepsilon_t$$

共享同一个 ε_t ，因而产生相关性。后续章节会把这种结构识别为一个不可逆的 MA(1) 表示。过度差分常导致负持续性，使后续建模更困难。

例 2.1 (温度趋势练习对应原文 Exercise 2.1). 原文要求对年度全球温度数据拟合式 (2.1)，检查残差图和一阶差分图，并思考：如果误差相关，普通线性回归输出的标准误为什么不可靠？核心原因是经典回归标准误通常依赖误差独立或弱相关假设；时间相关会改变

$$\widehat{\text{Var}}(\hat{\beta})$$

的结构，进而影响置信区间和显著性判断。

3 非参数方法

参数方法假设均值函数具有已知形式。但很多数据并没有明确的先验形状，此时可假设均值来自某个平滑函数：

$$\mu_t = \mu\left(\frac{t}{n}\right),$$

其中 $\mu(\cdot)$ 未知但足够平滑。

3.1 滚动窗口

一种简单方法是滚动窗口。原文特别介绍指数窗口，因为它可以在线更新。设 $t = 1$ 时

$$\hat{\mu}_1 = Y_1,$$

对 $t > 1$ 定义

$$\hat{\mu}_t = (1 - \lambda)\hat{\mu}_{t-1} + \lambda Y_t, \quad 0 < \lambda < 1.$$

λ 控制当前观测的权重。递推展开可见

$$\hat{\mu}_t = \sum_{j=1}^{t-1} (1 - \lambda)^{t-j} \lambda Y_j + (1 - \lambda)^{t-1} Y_1,$$

因此越新的观测权重越大，越旧的观测权重指数衰减。

3.2 筛估计

另一类非参数估计是筛估计。基本思想是用有限个基函数近似未知函数：

$$\mu(u) \approx \sum_{k=0}^{K_n} \alpha_k \phi_k(u).$$

常见基函数包括 Fourier 基、Haar 或其他小波基、样条基等。把 $u = t/n$ 代入后，趋势估计变成一个高维回归问题：

$$Y_t = \sum_{k=0}^{K_n} \alpha_k \phi_k(t/n) + \varepsilon_t.$$

K_n 随样本量增加而增长，因此筛估计介于参数模型和完全非参数模型之间。

4 什么是趋势，什么是噪声

原文提醒读者：趋势与噪声的区分并不总是由图形直接决定。一个平滑曲线既可能来自确定性均值，也可能是高度相关随机噪声的一次实现。特别是当误差存在强相关时，短样本图形中的缓慢变化可能被误读为趋势。

因此，趋势分析不应只依赖视觉判断。通常需要结合：

- 对均值结构的建模假设；
- 残差的自相关诊断；
- 差分后序列是否更接近平稳；
- 频域中是否存在明显低频或周期峰值。

5 周期函数

周期趋势是本章后半部分的重点。若月度均值每 12 个月重复一次，可以写成

$$\mu_t = \mu_{t+12}.$$

更一般地，周期为 P 的函数满足

$$d_P(t + P) = d_P(t).$$

5.1 正弦和余弦变换

当 $P = 12$ 时，原文把周期函数写为有限 Fourier 展开：

$$d_{12}(t) = a_0 + \sum_{j=1}^5 \left[a_j \cos\left(\frac{2\pi t j}{12}\right) + b_j \sin\left(\frac{2\pi t j}{12}\right) \right] + a_6 \cos(\pi t).$$

其中正弦、余弦项构成一组正交基。正交性使得系数可以通过内积分别估计：

$$a_j = \frac{1}{12} \sum_{t=1}^{12} d_{12}(t) \cos\left(\frac{2\pi t j}{12}\right), \quad b_j = \frac{1}{12} \sum_{t=1}^{12} d_{12}(t) \sin\left(\frac{2\pi t j}{12}\right),$$

常数因子取决于所采用的归一化约定。

5.2 Fourier 变换

复指数形式把正弦和余弦统一起来。对周期为 P 的函数，可写成

$$d_P(t) = \sum_{j=0}^{P-1} D_j \exp\left(i \frac{2\pi t j}{P}\right),$$

其中 Fourier 系数为

$$D_j = \frac{1}{P} \sum_{t=1}^P d_P(t) \exp\left(-i \frac{2\pi t j}{P}\right).$$

原文指出，当 $d_P(t)$ 是纯正弦或纯余弦时，其 Fourier 系数只会对应频率及其共轭频率处非零。这正是用频域寻找周期的基础。

5.3 离散 Fourier 变换

对有限样本 $Y_1, \dots, Y_n$ ，离散 Fourier 变换通常定义为

$$J_n(\omega) = \frac{1}{\sqrt{n}} \sum_{t=1}^n Y_t \exp(it\omega).$$

当频率取 Fourier 频率

$$\omega_j = \frac{2\pi j}{n}, \quad j = 0, \dots, n-1,$$

时， $\{J_n(\omega_j)\}$ 给出序列在不同频率上的复数投影。

定义 5.1 (周期图, 原文 Definition 2.5.1). 周期图是离散 Fourier 变换模平方的缩放版本:

$$I_n(\omega) = \frac{1}{n} \left| \sum_{t=1}^n Y_t \exp(it\omega) \right|^2 = |J_n(\omega)|^2.$$

它刻画样本序列在频率 ω 处的能量强度。

5.4 离散 Fourier 变换与周期信号

若信号中包含周期成分，周期图会在对应频率附近出现峰值。原文用周期为 4 的序列

$$d_4(s) = (1.125, -0.375, -0.375, -0.375)$$

说明：即使叠加独立噪声，周期图仍可能在与周期相对应的位置产生明显峰值。

对周期为 P 的正弦信号

$$\cos\left(\frac{2\pi t}{P}\right)$$

或

$$\sin\left(\frac{2\pi t}{P}\right),$$

主要能量集中在频率 $2\pi/P$ 以及对称频率处。因此，如果周期图峰值出现在 $\hat{\omega}$ ，对应周期可粗略估计为

$$\hat{P} = \frac{2\pi}{\hat{\omega}}.$$

5.5 平滑趋势及其 DFT

平滑趋势通常表现为低频能量较强。比如二次趋势

$$Y_t = \left(\frac{t}{n}\right)^2 + \varepsilon_t$$

的周期图会在靠近零频率处有较大能量。由此可见，低频峰值未必意味着周期，也可能表示缓慢变化的趋势。

5.6 周期检测

原文考虑含周期信号和噪声的模型：

$$Y_t = A \cos\left(\frac{2\pi t}{P}\right) + \varepsilon_t.$$

若 P 不大且样本量足够，周期图在 $2\pi/P$ 附近会出现峰值。实际检测时可在 Fourier 频率上寻找最大周期图值：

$$\hat{\omega} = \arg \max_{\omega_j} I_n(\omega_j), \quad \hat{P} = \frac{2\pi}{\hat{\omega}}.$$

这个估计思想简单，但受样本量、噪声强度、真实周期是否落在 Fourier 频率上等因素影响。

5.7 相关噪声下的周期检测

当噪声相关时，周期图不再像独立噪声那样“平坦”。相关噪声本身也可能在某些频率上有较高能量，从而掩盖或伪造周期峰值。原文通过较小样本 $n = 128$ 和较大样本 $n = 1024$ 的对比说明：样本量越大，真实周期峰值越容易从相关噪声背景中显现出来。

5.8 周期图简史

周期图最早与天文学和地球物理数据中的周期搜索密切相关。太阳黑子数据是经典例子：从 1749 年开始的月度太阳黑子数显示出约 11 年周期。原文 Figure 2.14 展示了太阳黑子数据及其周期图，峰值位置揭示了太阳活动的主要周期结构。

6 数据分析：EEG 数据

原文最后用 EEG 数据说明频率单位的转换和滤波实践。若时间序列以 F_s Hz 采样，即每秒 F_s 个观测，则数字频率 $\omega \in [0, \pi]$ 与物理频率 f (Hz) 的关系为

$$f = \frac{\omega}{2\pi} F_s.$$

例如采样率为 36 Hz 时，数字频率 ω 对应

$$f = \frac{36\omega}{2\pi}.$$

神经科学中常把 EEG 频段与认知状态联系起来，例如 α 、 β 等频段。原文通过周期图比较原始 EEG 和 Butterworth 滤波后的 EEG，说明滤波可以保留感兴趣频段、削弱低频漂移和低频噪声。若滤波目标是 8 到 32 Hz，在采样率已知时，需要先把这个频率区间转换到数字频率区间，再设计滤波器。

7 例题与练习补充

例 7.1 (原文 Example 2.5.1: 纯正弦和纯余弦). 若 $d_P(t) = \cos(2\pi t/P)$ 或 $d_P(t) = \sin(2\pi t/P)$, 其 *Fourier* 系数只集中在对应频率和共轭频率上。这说明周期图峰值可直接指示周期信号的频率。

例 7.2 (原文 Example 2.5.2: 含噪周期信号). 模型

$$Y_t = A \cos(2\pi t/P) + \varepsilon_t$$

在样本量适中、噪声不太强时, 会在 $\omega = 2\pi/P$ 附近产生周期图峰值。若噪声相关或样本很短, 峰值可能被扰动。

例 7.3 (EEG 频率换算). 若采样率为 36 Hz, 数字频率 $\omega = \pi/2$ 对应物理频率

$$f = \frac{36}{2\pi} \cdot \frac{\pi}{2} = 9 \text{ Hz}.$$

因此滤波器设计必须先把 Hz 区间转换为数字频率区间。

定义 7.1 (周期估计的基本规则). 若周期图最大峰值位于 $\hat{\omega}$, 则估计周期为 $\hat{P} = 2\pi/\hat{\omega}$ 。该规则适用于单一强周期成分, 但对多周期、趋势和相关噪声需要谨慎解释。

Exercise 2.1 要求拟合温度趋势、检查残差和一阶差分; Exercise 2.2 用模拟说明相关噪声会被误认为趋势; Exercise 2.3 要求自造周期序列并观察周期图; Exercise 2.4–2.6 则围绕 Fourier 变换、周期估计和重复模拟展开。

8 Python 工程实践

本项目把原文中的 R 绘图和模拟思想改写为 Python。当前脚本提供三张图: 参数趋势拟合、一阶差分和去趋势后的周期图。它们对应本章的三条主线: 趋势估计、差分处理和频域诊断。

在本章目录下运行:

```
python scripts/ch02_generate_figures.py
```

9 练习提要

原文第 2.7 节的练习围绕三类任务展开:

- 通过模拟和作图理解 Fourier 变换与周期图;
- 推导周期图在简单周期信号下的峰值位置;
- 反复模拟含周期信号的模型, 研究样本量、噪声强度和相关噪声对周期估计的影响。

讲义使用时, 可把每道练习继续拆成中文题面、公式提示和 Python 解答, 作为课堂作业或附加讲解材料。




图 1: 参数趋势估计示例: 对含二次趋势、季节成分和噪声的序列拟合二次趋势。




图 2: 一阶差分示例: 差分削弱慢趋势, 但也会改变噪声的依赖结构。




图 3: 周期图示例: 去除趋势后, 用周期图观察残差中的周期能量。

本章小结

第 2 章把时间序列中的趋势分成几种处理方式: 如果趋势形状已知, 可用参数回归或非线性最小二乘; 如果只知道趋势平滑, 可用滚动窗口或筛估计; 如果希望消去趋势, 可做差分; 如果趋势或信号具有周期性, 可借助 Fourier 变换和周期图。需要始终记住的是: 趋势、周期和相关噪声在有限样本图形中可能非常相似, 因此建模假设、残差诊断和频域分析应结合使用。